

Análise e Previsão da Produção de Petróleo no Campo Canto do Amaro

Handrey Heitor Alves da Costa

Resumo

Este trabalho apresenta uma análise de séries temporais aplicada à produção de petróleo do campo Canto do Amaro. Os dados foram organizados em uma série temporal mensal, compreendendo o período de 2005 a 2022. Foram realizadas análises gráficas, avaliação de sazonalidade, estudo das funções de autocorrelação, transformação de Box-Cox e diferenciação da série. Posteriormente, foram ajustados modelos ARIMA e TBATS, cujas previsões foram avaliadas por meio de medidas de erro. O objetivo principal foi investigar o comportamento temporal da produção e construir modelos capazes de prever valores futuros.

1 Introdução

A análise de séries temporais é utilizada para estudar observações registradas sequencialmente ao longo do tempo. Diferentemente de conjuntos de dados convencionais, as observações de uma série temporal podem apresentar dependência entre períodos, tendências, sazonalidade e mudanças de variabilidade.

Neste trabalho, foram analisados dados referentes à produção de petróleo do campo Canto do Amaro. O objetivo foi estudar o comportamento da produção ao longo dos anos e ajustar modelos estatísticos capazes de realizar previsões.

Foram considerados modelos da classe ARIMA, modelos ARIMA com componente sazonal e o modelo TBATS. A adequação dos modelos foi avaliada por meio da comparação entre valores observados e previstos.

2 Descrição dos dados

Os dados foram importados do arquivo `tabela_producao_oleo.csv`. Inicialmente, foram selecionadas apenas as observações correspondentes ao campo Canto do Amaro.

Em seguida, os registros foram agrupados de acordo com a variável que representa o período de observação. Para cada período, os valores da produção foram somados, desconsiderando possíveis valores ausentes.

O processamento resultou em uma tabela contendo duas informações principais:

- o período de observação;
- o total de barris produzido no período.

As manipulações foram realizadas com funções do pacote `dplyr`.

3 Construção da série temporal

Após a organização dos dados, os valores de produção foram convertidos em uma série temporal mensal por meio da função `ts`.

A série foi definida com início em janeiro de 2005, término em dezembro de 2022 e frequência igual a 12. A frequência 12 indica que existem doze observações em cada ano, correspondentes aos meses.

A representação gráfica inicial foi utilizada para verificar visualmente a presença de tendências, oscilações, valores atípicos e possíveis padrões sazonais.

4 Análise exploratória

4.1 Análise da sazonalidade

A função `seasonplot` foi utilizada para comparar o comportamento da produção entre os meses de diferentes anos.

Esse gráfico permite identificar se determinados meses apresentam padrões semelhantes ao longo do tempo. A repetição de um comportamento em períodos regulares pode indicar a presença de sazonalidade na série.

4.2 Autocorrelação

As funções de autocorrelação e autocorrelação parcial foram analisadas com a função `ggtsdisplay`.

A função de autocorrelação, ou ACF, mede a associação entre a série e seus próprios valores defasados. A função de autocorrelação parcial, ou PACF, mede a correlação entre duas observações após controlar o efeito das defasagens intermediárias.

Essas medidas auxiliam na identificação das ordens dos componentes autorregressivos e de médias móveis dos modelos ARIMA.

5 Transformação de Box-Cox

A transformação de Box-Cox foi aplicada para estabilizar a variância da série. O valor do parâmetro λ foi determinado automaticamente pela função `BoxCox.lambda`.

A transformação pode ser representada por:

$$y_t^{(\lambda)} = \begin{cases} \frac{y_t^\lambda - 1}{\lambda}, & \lambda \neq 0, \\ \log(y_t), & \lambda = 0. \end{cases}$$

Após a transformação, os gráficos da série, da ACF e da PACF foram analisados novamente para verificar possíveis alterações em sua estrutura.

6 Diferenciação da série

Para a utilização de modelos ARIMA, é importante que a série seja aproximadamente estacionária. Uma série estacionária apresenta média, variância e estrutura de autocorrelação relativamente constantes ao longo do tempo.

A função `ndiffs` foi utilizada para determinar o número recomendado de diferenciações comuns. Com base no resultado, foi aplicada uma diferenciação de primeira ordem:

$$\nabla y_t = y_t - y_{t-1}.$$

Também foi utilizada a função `nsdiffs` para investigar a necessidade de uma diferenciação sazonal.

Depois da diferenciação, a série foi novamente analisada por meio dos gráficos de autocorrelação.

7 Separação entre treinamento e validação

A série foi dividida em dois conjuntos:

- **Treinamento:** observações entre janeiro de 2005 e dezembro de 2015;
- **Validação:** observações a partir de janeiro de 2016.

O conjunto de treinamento foi utilizado para estimar os parâmetros dos modelos. O conjunto de validação foi reservado para avaliar a capacidade dos modelos de prever observações que não foram utilizadas durante o ajuste.

Essa separação evita avaliar o modelo utilizando apenas os mesmos dados empregados na estimação de seus parâmetros.

8 Modelos ARIMA

Os modelos ARIMA são representados pela notação $\text{ARIMA}(p, d, q)$, em que:

- p representa a ordem autorregressiva;
- d representa o número de diferenciações;
- q representa a ordem de médias móveis.

Quando há uma estrutura sazonal, o modelo pode ser representado por:

$$\text{ARIMA}(p, d, q)(P, D, Q)_s,$$

em que P , D e Q representam as ordens sazonais e s representa o período da sazonalidade. Para dados mensais, geralmente considera-se $s = 12$.

Inicialmente, a função `auto.arima` foi utilizada para pesquisar automaticamente uma especificação adequada. A busca foi executada sem aproximações e sem o procedimento simplificado de seleção, permitindo uma investigação mais ampla dos possíveis modelos.

Posteriormente, foi ajustado manualmente um modelo com a seguinte especificação:

$$\text{ARIMA}(1, 1, 0)(0, 0, 1)_{12},$$

incluindo um termo de tendência, denominado *drift*.

Também foi ajustado um segundo modelo:

$$\text{ARIMA}(0, 1, 0),$$

com termo de tendência. Esse modelo funciona como uma alternativa mais simples e pode ser comparado com o modelo que apresenta componentes autorregressivos e sazonais.

9 Avaliação dos modelos

Os coeficientes estimados foram analisados por meio das funções `summary` e `coeftest`. Essas funções permitem verificar os valores dos parâmetros, seus erros-padrão e sua significância estatística.

Os valores ajustados pelos modelos também foram comparados graficamente com os valores observados no conjunto de treinamento.

A função `accuracy` foi utilizada para calcular medidas de desempenho, como:

- erro médio absoluto, ou MAE;
- raiz do erro quadrático médio, ou RMSE;
- erro percentual absoluto médio, ou MAPE.

O MAE é calculado por:

$$MAE = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t|.$$

O RMSE é dado por:

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2}.$$

O MAPE é calculado por:

$$MAPE = \frac{100}{n} \sum_{t=1}^n \left| \frac{y_t - \hat{y}_t}{y_t} \right|.$$

Em geral, menores valores dessas medidas indicam previsões mais próximas dos valores observados.

10 Previsões

Inicialmente, foi produzida uma previsão de um período à frente. Posteriormente, foram realizadas previsões para os doze meses seguintes.

As previsões foram apresentadas graficamente com seus respectivos intervalos de previsão. Também foi realizada uma comparação visual entre os valores previstos e os valores observados no conjunto de validação.

Para uma avaliação correta da previsão de doze meses, devem ser considerados os doze primeiros meses do conjunto de validação. Caso todo o período de validação seja utilizado, o horizonte da previsão deve ser definido como o número total de observações disponíveis nesse conjunto.

11 Modelo TBATS

Além dos modelos ARIMA, foi ajustado um modelo TBATS. O nome TBATS representa a combinação de:

- transformação de Box-Cox;
- erros do tipo ARMA;
- tendência;
- componentes sazonais trigonométricos.

Esse modelo é especialmente útil para séries que apresentam padrões sazonais complexos ou que mudam ao longo do tempo.

O horizonte de previsão do TBATS foi definido de acordo com o número de observações presentes no conjunto de validação. Suas previsões foram comparadas com os valores observados utilizando as mesmas medidas de erro aplicadas aos modelos ARIMA.

12 Conclusão

Neste trabalho foi desenvolvida uma análise da produção de petróleo do campo Canto do Amaro utilizando técnicas de séries temporais.

Inicialmente, os dados foram filtrados, agrupados e convertidos em uma série mensal. Em seguida, foram analisados os padrões temporais, a sazonalidade e a estrutura de autocorrelação da série.

A transformação de Box-Cox e a diferenciação foram utilizadas para melhorar as propriedades estatísticas dos dados. Posteriormente, foram ajustados diferentes modelos ARIMA e um modelo TBATS.

A escolha do modelo final deve ser baseada na análise dos resíduos, na significância dos coeficientes e, principalmente, nos erros obtidos no conjunto de validação. O modelo que apresentar menores valores de MAE, RMSE e MAPE, juntamente com resíduos sem autocorrelação significativa, poderá ser considerado o mais adequado para prever a produção futura.